Apunte de la Fase 4

Consolidación del proyecto, visualización de datos y comunicación de resultados

> **El cambio de foco.** Las tres fases anteriores tenían por objeto los datos y el código. La Fase 4 tiene por objeto al lector: qué necesita saber, en qué orden, con qué evidencia y con qué advertencias. Un resultado que no se comunica no existe para nadie más que para quien lo obtuvo.

1. Qué significa consolidar un proyecto

Consolidar no es reunir los entregables anteriores en una carpeta. Es producir un artefacto único en el que las cuatro fases se leen como un proceso coherente, cada decisión queda justificada y cualquier afirmación puede verificarse contra la evidencia.

> **Reproducibilidad.** Propiedad de un trabajo que permite a un tercero obtener los mismos resultados con los mismos datos y el mismo código. Es una propiedad del conjunto: basta un eslabón roto, como una dependencia sin versión, para perderla.

> **Trazabilidad.** Posibilidad de reconstruir quién hizo qué, cuándo y por qué. No se refiere a los resultados sino al proceso que los produjo.

Son propiedades distintas y ambas se evalúan. Un proyecto puede ser reproducible sin ser trazable, si el código corre pero nadie sabe por qué se tomaron esas decisiones. Y puede ser trazable sin ser reproducible, si cada decisión está documentada pero el entorno no se puede reconstruir.

La consolidación tiene tres direcciones

Hacia atrás, corrigiendo lo observado en las fases anteriores. De los veintiséis criterios de la rúbrica, catorce vuelven a evaluar trabajo ya entregado, de modo que la retroalimentación recibida define buena parte de las tareas de esta fase.

Hacia adentro, verificando la coherencia entre los cuatro productos. El informe, los notebooks, el repositorio y la presentación deben afirmar lo mismo. La incoherencia entre ellos no es un defecto formal: destruye la credibilidad del conjunto, porque obliga a quien evalúa a comprobar todo lo demás.

Hacia adelante, dejando el trabajo en condiciones de continuar. Un proyecto bien consolidado permite que alguien retome el análisis meses después sin volver a preguntar nada.

El registro de cambios como instrumento

> **Registro de cambios.** Documento que consigna, en orden cronológico, qué se modificó, cuándo, por qué razón y en qué punto del historial de versiones quedó registrado.

Su función no es administrativa sino argumental: demuestra que el proyecto evolucionó por decisiones y no por acumulación. Cada entrada vincula una observación recibida con la acción de mejora y con su efecto sobre la modularidad, el rendimiento o la documentación.

2. Por qué se visualiza

La visualización cumple dos funciones que conviene no confundir, porque exigen gráficos distintos.

Función	Para qué sirve	Características del gráfico
Exploratoria	Que el analista descubra estructura en los datos	Rápida, abundante, sin rotular; se descarta después
Explicativa	Que un tercero comprenda un hallazgo determinado	Escasa, seleccionada, rotulada e interpretada

El error más frecuente en un informe es incluir gráficos exploratorios. Se reconocen porque no tienen un mensaje: muestran algo sin afirmar nada. La Fase 4 pide visualización explicativa, que es un producto de comunicación y no un subproducto del análisis.

> **El principio que ordena la fase.** Un gráfico responde una pregunta. Si la figura no responde alguno de los objetivos específicos declarados en la Fase 1, no pertenece al informe. Y si un objetivo no tiene figura que lo responda, el trabajo está incompleto.

3. Fundamentos perceptuales de la visualización

La elección del tipo de gráfico no es una cuestión de gusto. Existe evidencia experimental sobre qué tan bien el sistema visual humano estima magnitudes según cómo estén codificadas.

> **Canal de codificación.** Atributo visual mediante el cual un dato se representa: posición, longitud, ángulo, área, color, textura. Cada canal tiene una precisión distinta para transmitir cantidades.

Jerarquía de precisión de los canales

Los estudios sobre tareas perceptuales elementales establecen un orden de precisión decreciente que tiene consecuencias directas sobre qué gráfico conviene usar.

Orden	Canal	Gráfico que lo utiliza
1	Posición sobre una escala común	Dispersión, líneas, puntos alineados
2	Posición sobre escalas no alineadas	Paneles múltiples
3	Longitud	Barras
4	Ángulo o pendiente	Gráfico circular
5	Área	Burbujas, mapas de árbol
6	Intensidad de color	Mapas de calor

De ahí se sigue la recomendación de preferir barras sobre gráficos circulares: comparar longitudes es una tarea perceptual más precisa que comparar ángulos. No es una convención estética, es una consecuencia de cómo funciona la percepción.

Atributos preatentivos

> **Atributo preatentivo.** Propiedad visual que el sistema perceptual procesa antes de la atención consciente, en menos de un cuarto de segundo: color, orientación, tamaño, movimiento.

Esto explica por qué funciona el color usado con función. Si todas las barras son grises salvo una, el ojo localiza esa barra sin buscarla. Si cada barra tiene un color distinto, el mecanismo se desactiva y la mirada se reparte sin dirección.

Principios de agrupamiento

La percepción organiza los elementos visuales en unidades antes de interpretarlos. Tres principios operan en cualquier gráfico: los elementos próximos se perciben como grupo, los elementos similares se perciben como pertenecientes a una misma categoría, y los elementos encerrados por un límite común se perciben como un conjunto.

Esto fundamenta decisiones concretas: separar las barras de grupos distintos, usar un mismo color para una misma serie a lo largo de todas las figuras, y recuadrar lo que constituye una unidad de lectura.

4. La gramática de un gráfico

Una visualización puede descomponerse en elementos independientes que se combinan. Esa descomposición, conocida como gramática de gráficos, es la que está detrás de las librerías del ecosistema científico.

Elemento	Qué define
Datos	La tabla que se representa, normalmente agregada
Estética	Qué variable se asigna a qué canal: eje, color, tamaño
Geometría	La forma que adopta cada observación: barra, punto, línea
Escala	Cómo se traducen los valores a la posición o al color
Rotulado	Título, ejes, leyenda, anotación y fuente

Pensar en estos términos ordena la construcción: primero se decide qué tabla se grafica, después qué variable va en cada canal, y solo al final qué función de la librería se llama. Quien parte eligiendo la función suele terminar forzando los datos a la forma del gráfico.

División de trabajo entre librerías

El programa del módulo declara cuatro librerías y cada una ocupa un lugar distinto en esta gramática.

Librería	Función en la Fase 4
NumPy	Cálculo numérico: percentiles, ajustes de tendencia, transformaciones de escala
pandas	Construcción de la tabla que se grafica: agrupaciones, tablas cruzadas, pivotes
seaborn	Geometría y estética de los gráficos estadísticos
Matplotlib	Escalas, rotulado, anotación, composición y exportación

La regla operativa: seaborn dibuja el gráfico estadístico, Matplotlib lo termina. El rotulado que el entregable exige pertenece casi siempre a la segunda.

5. Preparación de los datos para visualizar

El conjunto que resulta de un pipeline de preparación está optimizado para el análisis numérico, no para la lectura humana. Dos transformaciones habituales lo hacen ilegible.

La **codificación de categóricas** convierte una variable con etiquetas en un conjunto de columnas indicadoras de ceros y unos. La categoría deja de existir como tal.

El **escalamiento** centra y reescala las variables continuas, de modo que pierden su unidad de medida. Un valor de menos 0,43 no admite interpretación sustantiva.

> **La consecuencia práctica.** Un proyecto necesita dos versiones del conjunto: la matriz transformada, para el análisis, y una copia interpretable con categorías y unidades originales, para las visualizaciones. Ninguna de las dos es más correcta que la otra: sirven para propósitos distintos.

Reversión de las transformaciones

Si el pipeline registró los parámetros que aprendió, las transformaciones son invertibles de forma exacta. Para el escalamiento estándar, si m es la media, s la desviación y z el valor transformado, el valor original se recupera como $z \cdot s + m$. Para la codificación, el vocabulario de categorías permite reconstruir la variable original desde las columnas indicadoras.

Esa es la razón por la que la fase anterior debía entregar el registro de parámetros. La alternativa, volver al archivo original, no garantiza la correspondencia fila a fila después de un filtrado o una partición.

Variables ordinales y orden de categorías

Una variable ordinal tiene un orden inherente que el tipo de dato no conoce. Si se grafica sin declararlo, las categorías aparecen en orden alfabético y la figura sugiere una secuencia falsa. Declarar el orden es parte de la preparación, no un ajuste estético.

Agregación previa

Casi ninguna figura se construye sobre las observaciones individuales: se construye sobre una tabla resumen. Conviene calcularla en un paso separado para poder verificarla, y conviene que incluya siempre el tamaño de cada grupo.

El tamaño de los grupos es una advertencia, no un dato accesorio. Una barra calculada sobre ocho observaciones ocupa el mismo espacio visual que una calculada sobre dos mil, y transmite una certeza que no tiene. Si algún grupo es pequeño, corresponde declararlo en la figura o agruparlo.

6. Principios de diseño de la figura

Economía visual

> **Razón entre datos y tinta.** Proporción de los elementos gráficos que representan información respecto del total de elementos dibujados. Todo lo que no representa un dato compite por la atención sin aportar.

De este principio derivan recomendaciones concretas: eliminar bordes, sombras y fondos decorativos; reducir las líneas de cuadrícula; suprimir las leyendas cuando se puede rotular directamente la serie.

Fidelidad de la representación

> **Factor de mentira.** Cociente entre el tamaño del efecto mostrado en el gráfico y el tamaño del efecto presente en los datos. Un gráfico honesto tiene un factor cercano a uno.

El caso más común de distorsión es el eje que no parte en cero en un gráfico de barras. Como la longitud de la barra codifica la magnitud, recortar el eje multiplica visualmente una diferencia pequeña. En gráficos de líneas la regla es distinta, porque lo que se representa es la variación y no la magnitud absoluta: allí recortar el eje es admisible si se declara.

El título como enunciado

Un título puede rotular o afirmar. El rótulo indica de qué trata la figura; el enunciado comunica lo que se encontró. En un informe técnico corresponde el segundo, porque quien lee recorre las figuras antes que el texto y el título es lo único que retiene de cada una.

Uso del color

Tipo de paleta	Cuándo corresponde	Ejemplo de uso
Secuencial	Variable numérica ordenada de menor a mayor	Intensidad en un mapa de calor
Divergente	Variable con un punto medio significativo	Correlaciones centradas en cero
Cualitativa	Categorías sin orden entre sí	Series de distintos grupos

Usar una paleta cualitativa para una variable ordenada elimina la información de orden. Usar una secuencial para categorías sin orden sugiere una jerarquía inexistente.

> **Accesibilidad.** Cerca del ocho por ciento de los hombres presenta alguna deficiencia en la visión del color, habitualmente en la distinción entre rojo y verde. El color nunca debe ser el único canal que transmite una información: debe acompañarse de posición, orden, etiqueta o forma.

7. Las librerías y su función en el proyecto

El programa del módulo declara un conjunto acotado de herramientas. Cada una ocupa un lugar distinto en la gramática descrita en el apartado anterior, y conocer esa división permite justificar su uso en el informe en vez de enumerarlas.

Librería	Qué aporta	Dónde se manifiesta
NumPy	Cálculo numérico sobre arreglos: percentiles, ajustes de tendencia, operaciones vectorizadas, generación reproducible de valores aleatorios	Mediciones de eficiencia y cálculos que alimentan las figuras
pandas	Estructura tabular y manipulación: lectura, agrupación, tablas cruzadas, pivotes y uniones	Construcción de la tabla que se grafica
Matplotlib	Control de la figura: escalas, ejes, anotaciones, composición de paneles y exportación	Rotulado exigido por la rúbrica y guardado de figuras
seaborn	Geometría y estética de los gráficos estadísticos de uso frecuente	La mayoría de las figuras del informe
Jupyter	Entorno que integra código, resultado y explicación en un mismo documento	El notebook, entregable central
Git y GitHub	Control de versiones y colaboración	Trazabilidad y repositorio

> **División de trabajo.** seaborn dibuja el gráfico estadístico y Matplotlib lo termina. El título que enuncia el hallazgo, la anotación y la fuente pertenecen casi siempre a la segunda. Declarar librerías que el proyecto no utiliza introduce ruido que resta precisión al informe.

Los ejemplos del apartado siguiente suponen esta configuración inicial.

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

sns.set_theme(style="whitegrid", palette="deep")
plt.rcParams.update({"figure.dpi": 110, "axes.titleweight": "bold"})

DESTACADO = "#AC212E"   # aquello sobre lo que se dirige la mirada
NEUTRO    = "#9FB6C8"   # el contexto
```

8. Catálogo de gráficos

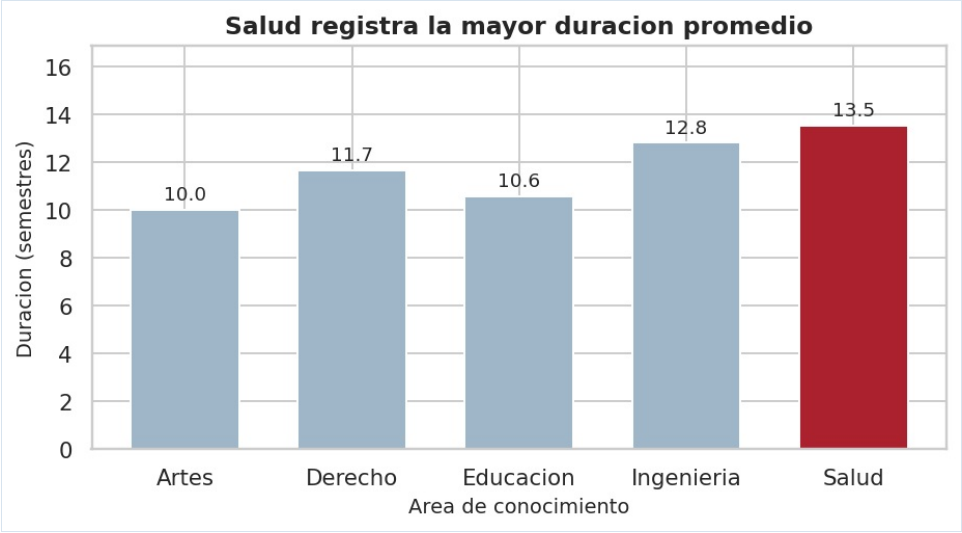
Cada entrada señala qué representa el gráfico, cuándo corresponde emplearlo, qué comunica, cómo se programa y qué precaución exige. La elección se decide por la forma de la pregunta y no por la apariencia del resultado.

8.1 Barras verticales

Qué muestra. Una medida por categoría. **Cuándo usarlo.** Para comparar magnitudes entre pocos grupos, hasta seis o siete. **Qué comunica.** Cuál grupo tiene más y de qué tamaño es la diferencia.

```
resumen = df.groupby("categoria", observed=True)["valor"].mean()

fig, eje = plt.subplots(figsize=(8, 4.5))
colores = [DESTACADO if v == resumen.max() else NEUTRO for v in resumen]
barras = eje.bar(resumen.index.astype(str), resumen.values, color=colores, width=0.65)
eje.bar_label(barras, fmt="%.1f", padding=3)
eje.set_title("Enunciado del hallazgo")
eje.set_xlabel("Categoria"); eje.set_ylabel("Medida (unidad)")
eje.set_ylim(0, resumen.max() * 1.25)
plt.tight_layout(); plt.show()
```



Ejemplo generado con el código anterior

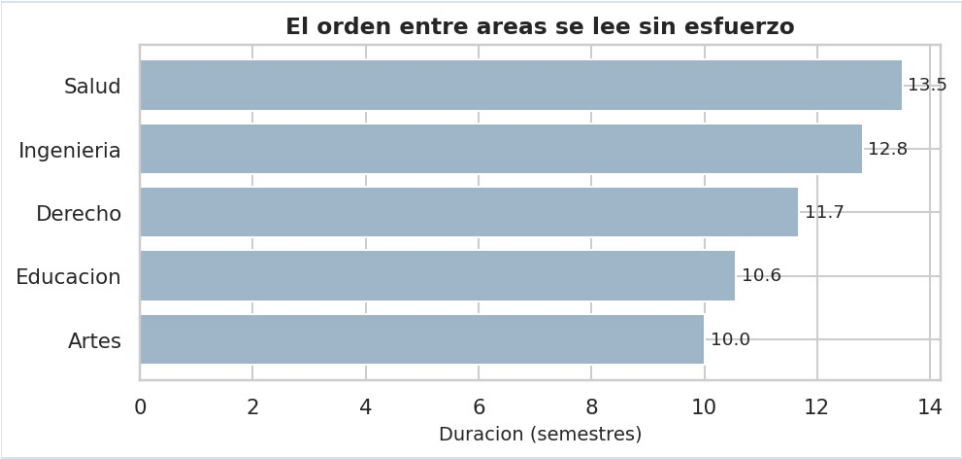
Precaución. El eje vertical debe partir en cero. Como la longitud codifica la magnitud, recortarlo eleva el factor de mentira y multiplica visualmente una diferencia pequeña. Ordenar por valor, salvo que la categoría tenga un orden propio.

8.2 Barras horizontales

Qué muestra. Lo mismo que las verticales. **Cuándo usarlo.** Cuando las etiquetas son extensas o hay muchas categorías. **Qué comunica.** El orden entre categorías, legible de un vistazo.

```
resumen = df.groupby("categoria", observed=True)["valor"].mean().sort_values()

fig, eje = plt.subplots(figsize=(8, 4.5))
barras = eje.barh(resumen.index, resumen.values, color=NEUTRO)
eje.bar_label(barras, fmt="%.1f", padding=3)
eje.set_xlabel("Medida (unidad)"); eje.set_ylabel("")
plt.tight_layout(); plt.show()
```



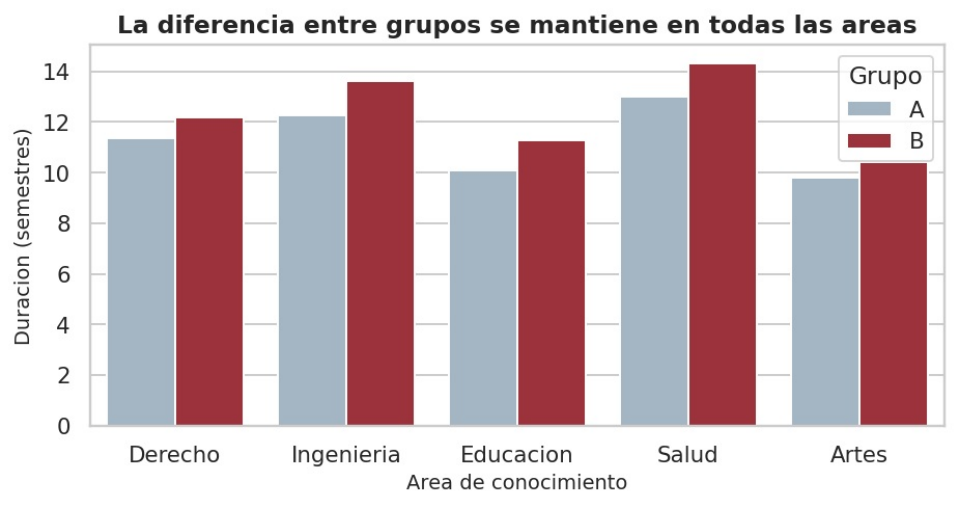
Ejemplo generado con el código anterior

Precaución. Evitan rotar las etiquetas, que es lo que degrada la legibilidad de las barras verticales con nombres largos.

8.3 Barras agrupadas

Qué muestra. Una medida por categoría, subdividida por una segunda variable. **Cuándo usarlo.** Para comparar dos o tres series entre las mismas categorías. **Qué comunica.** Si la diferencia entre series se mantiene o se invierte según la categoría.

```
fig, eje = plt.subplots(figsize=(9, 4.5))
sns.barplot(data=df, x="categoria", y="valor", hue="grupo",
            errorbar=None, palette=[NEUTRO, DESTACADO], ax=eje)
eje.legend(title="Grupo")
plt.tight_layout(); plt.show()
```



Ejemplo generado con el código anterior

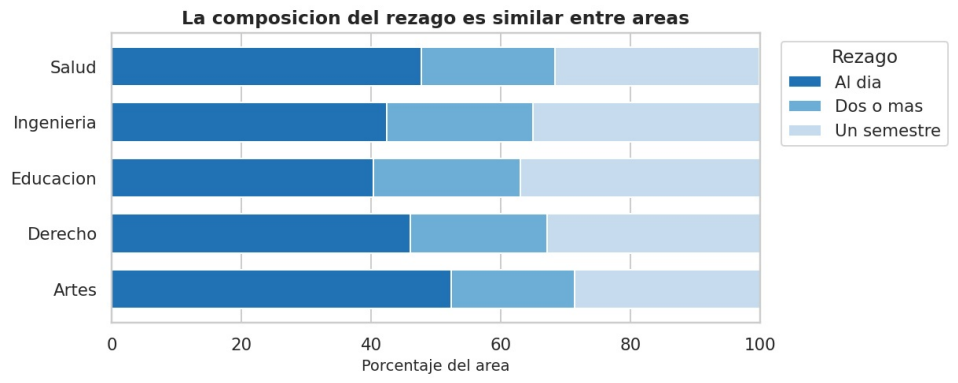
Precaución. Con más de tres series las barras se adelgazan y la comparación deja de ser viable. En ese caso corresponden paneles múltiples.

8.4 Barras apiladas y al cien por ciento

Qué muestra. La composición de un total. **Cuándo usarlo.** Para representar de qué partes se compone cada grupo. **Qué comunica.** Cómo cambia la proporción de cada componente entre grupos.

```
composicion = (pd.crosstab(df["grupo"], df["componente"], normalize="index")
               .mul(100).round(1))

fig, eje = plt.subplots(figsize=(9, 4.5))
composicion.plot(kind="barh", stacked=True, ax=eje,
                 color=sns.color_palette("Blues_r", composicion.shape[1]), width=0.7)
eje.legend(title="Componente", bbox_to_anchor=(1.02, 1), loc="upper left")
eje.set_xlim(0, 100); eje.set_xlabel("Porcentaje del grupo")
plt.tight_layout(); plt.show()
```



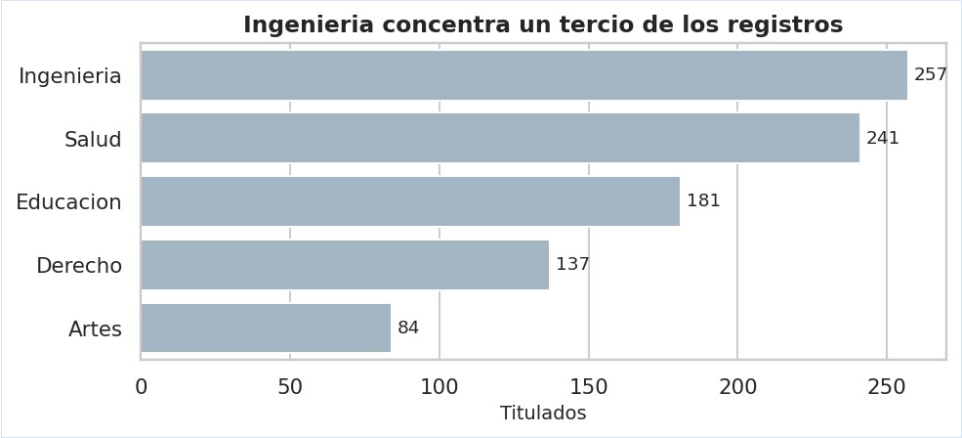
Ejemplo generado con el código anterior

Precaución. Solo el primer y el último componente comparten una línea base común, de modo que los intermedios se comparan con dificultad. No conviene apilar más de cuatro o cinco. Normalizar a cien permite comparar grupos de tamaños distintos.

8.5 Gráfico de conteo

Qué muestra. Cuántas observaciones hay en cada categoría. **Cuándo usarlo.** Para describir la composición del conjunto antes de analizarlo. **Qué comunica.** Si los grupos están equilibrados o alguno es marginal.

```
fig, eje = plt.subplots(figsize=(8, 4.2))
sns.countplot(data=df, y="categoria", color=NEUTRO,
              order=df["categoria"].value_counts().index, ax=eje)
eje.bar_label(eje.containers[0], padding=3)
plt.tight_layout(); plt.show()
```



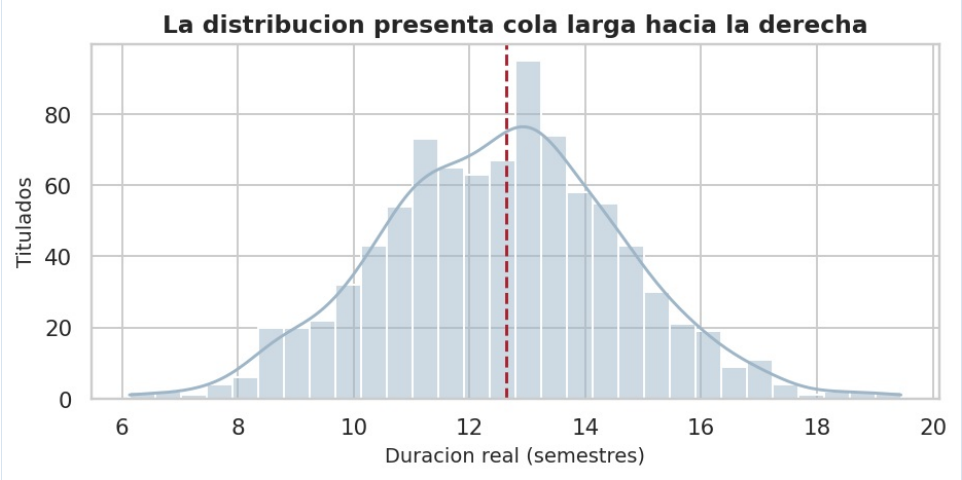
Ejemplo generado con el código anterior

Precaución. Su lugar habitual son los anexos. Constituye, sin embargo, la evidencia de que el tamaño de los grupos fue revisado antes de comparar tasas.

8.6 Histograma

Qué muestra. Cómo se reparten los valores de una variable continua. **Cuándo usarlo.** Para conocer la forma de una distribución. **Qué comunica.** Si es simétrica, si presenta cola larga, si tiene más de un pico.

```
fig, eje = plt.subplots(figsize=(8, 4.2))
sns.histplot(data=df, x="variable", bins=30, color=NEUTRO, kde=True, ax=eje)
eje.axvline(df["variable"].median(), color=DESTACADO, linestyle="--")
eje.set_xlabel("Variable (unidad)"); eje.set_ylabel("Observaciones")
plt.tight_layout(); plt.show()
```



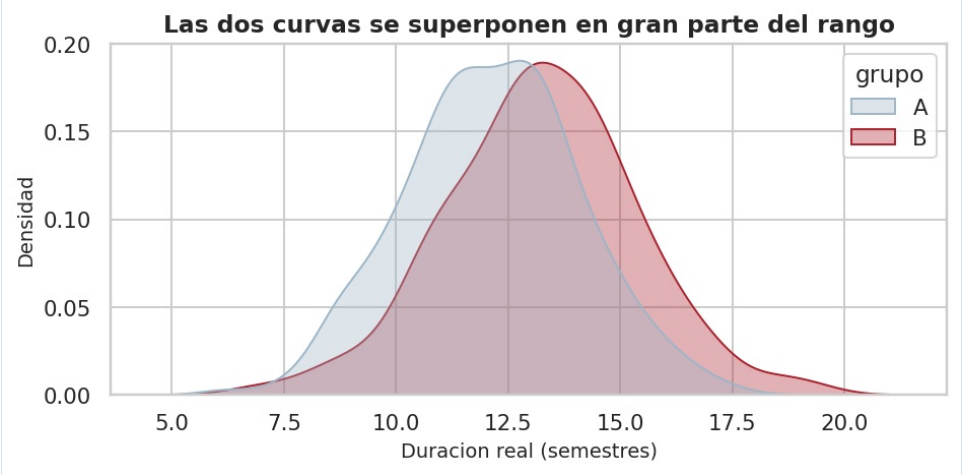
Ejemplo generado con el código anterior

Precaución. El número de intervalos altera la lectura: con pocos se pierden detalles, con demasiados aparece ruido que simula estructura. Conviene declarar cuál se usó. Con menos de treinta observaciones, la figura refleja el azar más que la distribución.

8.7 Densidad

Qué muestra. Una versión suavizada de la distribución. **Cuándo usarlo.** Para comparar la forma de dos o tres grupos en una misma figura. **Qué comunica.** Dónde se concentra cada grupo y cuánto se superponen.

```
fig, eje = plt.subplots(figsize=(8, 4.2))
sns.kdeplot(data=df, x="variable", hue="grupo", fill=True, alpha=0.35,
            common_norm=False, palette=[NEUTRO, DESTACADO], ax=eje)
plt.tight_layout(); plt.show()
```



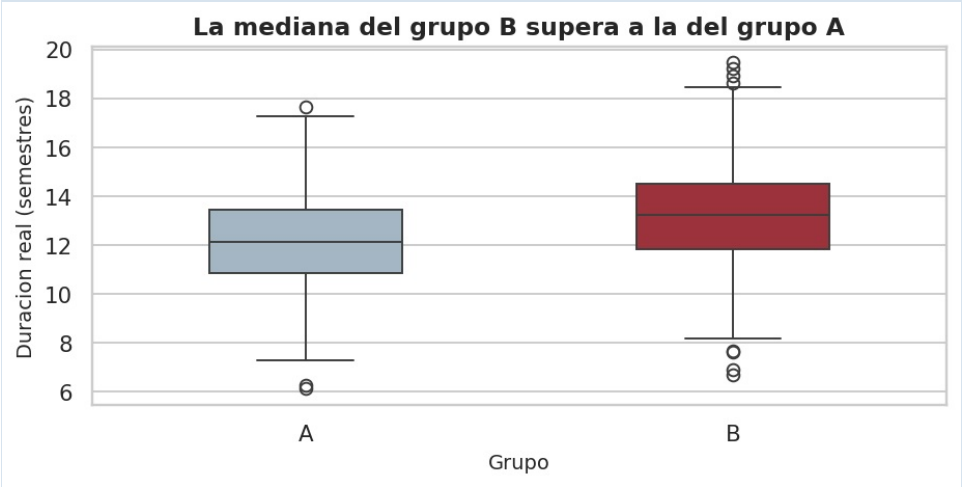
Ejemplo generado con el código anterior

Precaución. El argumento `common_norm=False` normaliza cada curva por separado, de modo que grupos de tamaños distintos resulten comparables en forma. Sin él, el grupo más numeroso domina la figura.

8.8 Gráfico de caja

Qué muestra. Mediana, cuartiles y valores extremos. **Cuándo usarlo.** Para comparar valor central y dispersión entre grupos. **Qué comunica.** Si un grupo se sitúa sistemáticamente por encima de otro y cuánto varía cada uno.

```
fig, eje = plt.subplots(figsize=(8, 4.5))
sns.boxplot(data=df, x="grupo", y="variable", hue="grupo", legend=False,
            palette=[NEUTRO, DESTACADO], width=0.45, ax=eje)
plt.tight_layout(); plt.show()
```



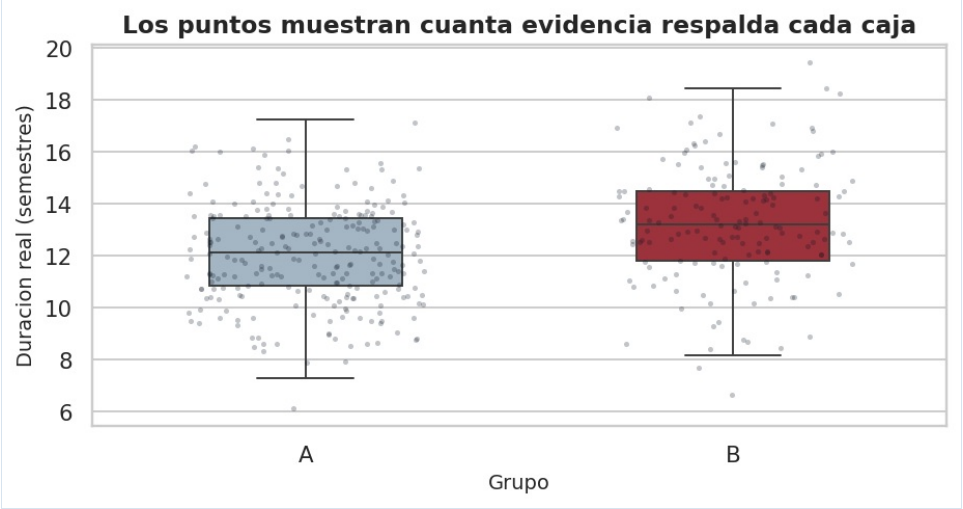
Ejemplo generado con el código anterior

Precaución. Es robusto a valores extremos porque emplea mediana y cuartiles, lo que lo hace preferible con distribuciones de cola larga. Pero oculta el tamaño de los grupos: la caja de quince observaciones se ve tan sólida como la de dos mil.

8.9 Caja con puntos superpuestos

Qué muestra. El resumen de la caja junto a la densidad real de observaciones. **Cuándo usarlo.** Cuando el tamaño de los grupos condiciona la lectura. **Qué comunica.** Cuánta evidencia respalda cada caja.

```
fig, eje = plt.subplots(figsize=(8, 4.5))
sns.boxplot(data=df, x="grupo", y="variable", hue="grupo", legend=False,
            palette=[NEUTRO, DESTACADO], width=0.45, fliersize=0, ax=eje)
sns.stripplot(data=df.sample(min(500, len(df)), random_state=42),
              x="grupo", y="variable", size=2.6, color="#0A1526",
              alpha=0.25, jitter=0.28, ax=eje)
plt.tight_layout(); plt.show()
```



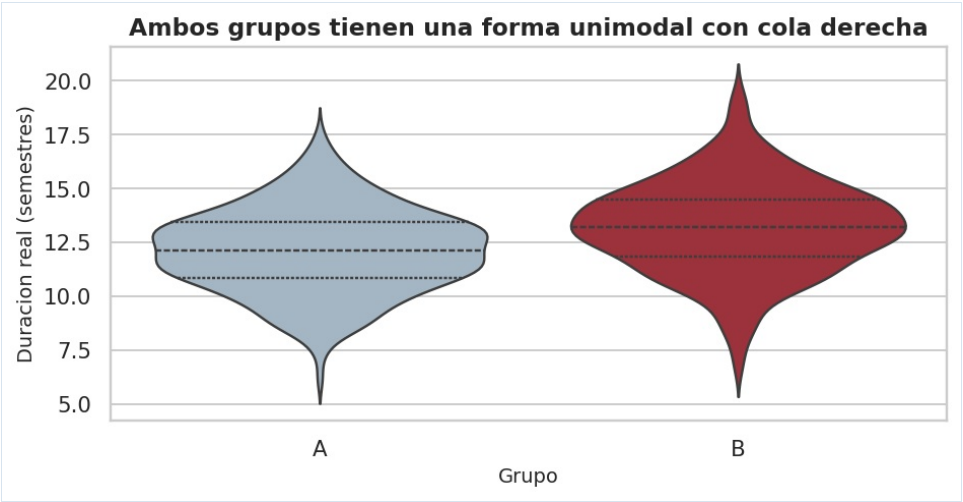
Ejemplo generado con el código anterior

Precaución. El argumento `fliersize=0` evita dibujar dos veces los valores extremos. Es la combinación más recomendable para comparar grupos en un informe.

8.10 Violín

Qué muestra. La forma de la distribución en cada grupo. **Cuándo usarlo.** Cuando la forma importa, por ejemplo ante la sospecha de bimodalidad. **Qué comunica.** Diferencias que el gráfico de caja no revela.

```
fig, eje = plt.subplots(figsize=(8, 4.5))
sns.violinplot(data=df, x="grupo", y="variable", hue="grupo", legend=False,
               palette=[NEUTRO, DESTACADO], inner="quartile", ax=eje)
plt.tight_layout(); plt.show()
```



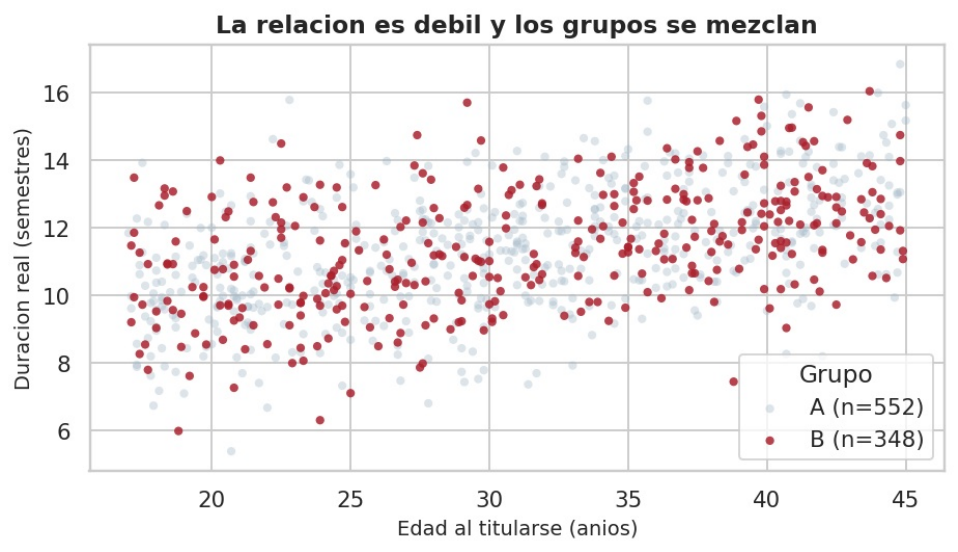
Ejemplo generado con el código anterior

Precaución. Con menos de treinta observaciones por grupo, la curva de densidad atribuye a los datos una suavidad que no poseen.

8.11 Dispersión

Qué muestra. Cada observación como un punto en dos ejes. **Cuándo usarlo.** Para examinar la relación entre dos variables continuas. **Qué comunica.** Presencia de tendencia, agrupamientos o valores atípicos.

```
fig, eje = plt.subplots(figsize=(8, 5))
for grupo, color, alfa in [("A", NEUTRO, 0.35), ("B", DESTACADO, 0.85)]:
    sub = df[df["grupo"] == grupo]
    eje.scatter(sub["x"], sub["y"], s=20, alpha=alfa, color=color,
                edgecolors="none", label=f"{grupo} (n={len(sub)})")
eje.legend(title="Grupo")
eje.set_xlabel("Variable X (unidad)"); eje.set_ylabel("Variable Y (unidad)")
plt.tight_layout(); plt.show()
```



Ejemplo generado con el código anterior

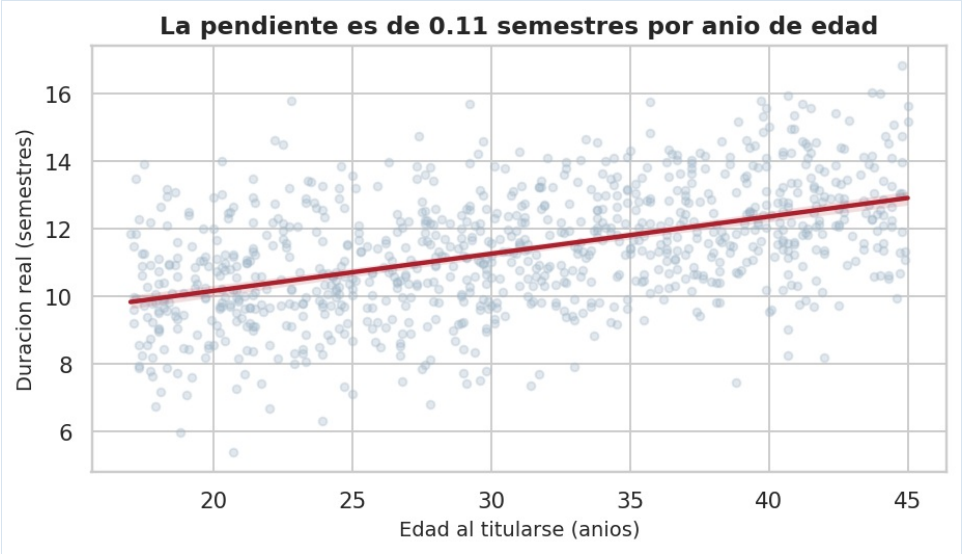
Precaución. Con miles de puntos superpuestos, la transparencia definida por `alpha` es lo que permite percibir la densidad. Una dispersión muestra asociación y nunca causalidad.

8.12 Dispersión con línea de tendencia

Qué muestra. La relación entre dos variables junto a su ajuste lineal. **Cuándo usarlo.** Cuando se desea cuantificar la dirección y la magnitud de la relación. **Qué comunica.** Cuánto cambia una variable por unidad de la otra.

```
fig, eje = plt.subplots(figsize=(8, 5))
sns.regplot(data=df, x="x", y="y", scatter_kws={"s": 18, "alpha": 0.3},
            line_kws={"color": DESTACADO}, ax=eje)

coef = np.polyfit(df["x"], df["y"], deg=1)
print(f"Pendiente: {coef[0]:.3f} unidades de Y por unidad de X")
plt.tight_layout(); plt.show()
```



Ejemplo generado con el código anterior

Precaución. Reportar la pendiente convierte una impresión visual en una cifra. El ajuste lineal describe la relación promedio y puede ocultar estructuras curvas.

8.13 Líneas

Qué muestra. Cómo cambia una medida a lo largo de una secuencia ordenada. **Cuándo usarlo.** Con tiempo, tramos ordenados o niveles de una escala. **Qué comunica.** Tendencia, quiebres y velocidad del cambio.

```
serie = df.groupby("periodo", observed=True)["valor"].mean()

fig, eje = plt.subplots(figsize=(8, 4.5))
eje.plot(serie.index.astype(str), serie.values, marker="o", linewidth=2.2, color=DESTACADO)
eje.fill_between(range(len(serie)), serie.values, alpha=0.12, color=DESTACADO)
eje.set_xlabel("Periodo"); eje.set_ylabel("Medida (unidad)")
plt.tight_layout(); plt.show()
```



Ejemplo generado con el código anterior

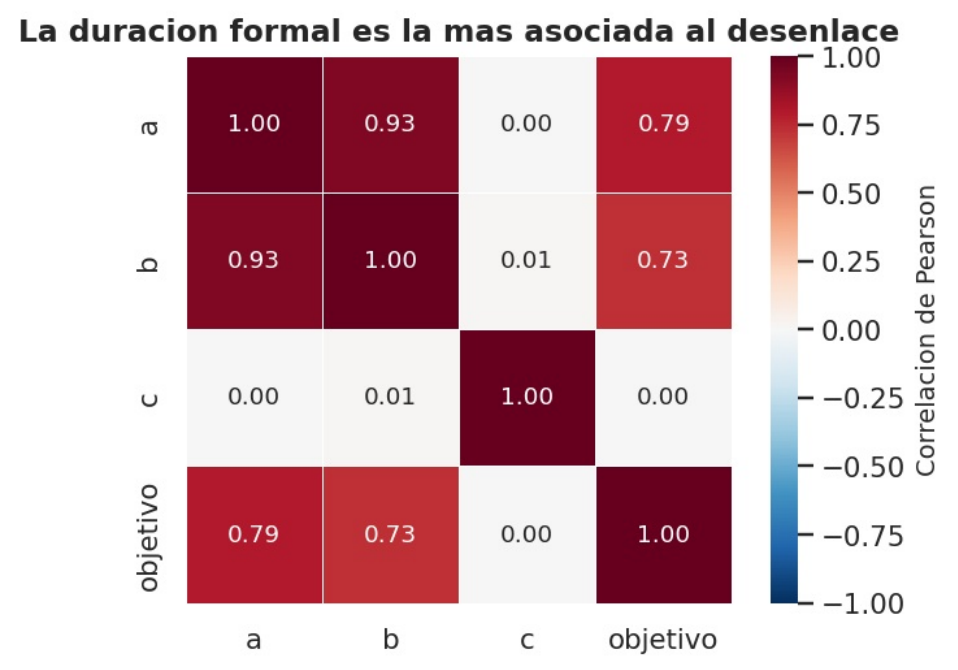
Precaución. La línea sugiere continuidad entre puntos, de modo que no corresponde con categorías nominales. Aquí sí es admisible recortar el eje vertical, porque lo representado es la variación y no la magnitud, siempre que se declare.

8.14 Mapa de calor de correlaciones

Qué muestra. La relación lineal entre todos los pares de variables numéricas. **Cuándo usarlo.** Como panorama inicial, para decidir qué relaciones examinar. **Qué comunica.** Qué variables varían conjuntamente.

```
correlaciones = df[["a", "b", "c", "objetivo"]].corr()

fig, eje = plt.subplots(figsize=(6.5, 5))
sns.heatmap(correlaciones, annot=True, fmt=".2f", cmap="RdBu_r",
            center=0, vmin=-1, vmax=1, square=True, linewidths=0.5,
            cbar_kws={"label": "Correlacion de Pearson"}, ax=eje)
plt.tight_layout(); plt.show()
```



Ejemplo generado con el código anterior

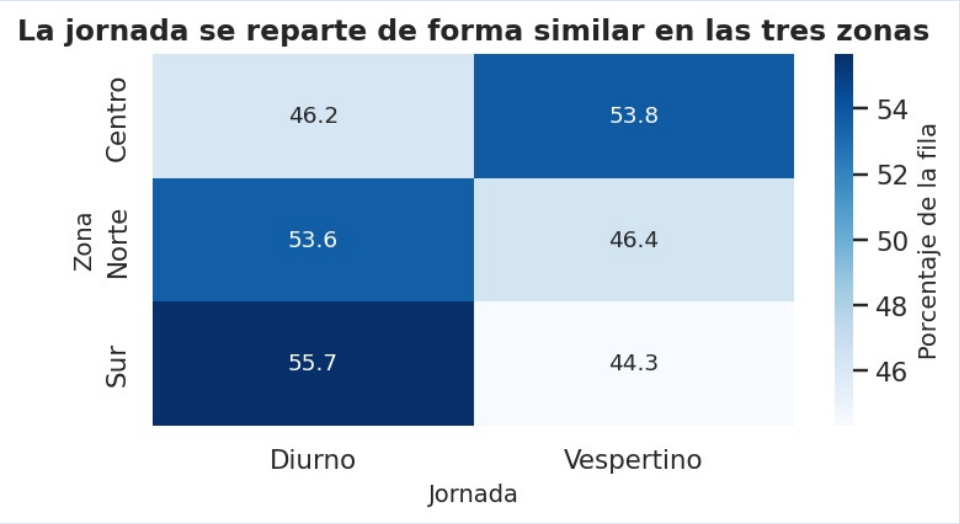
Precaución. La escala debe fijarse de menos uno a uno y centrarse en cero. Con escala automática, un conjunto de correlaciones bajas aparece con colores intensos y sugiere asociaciones inexistentes. La correlación de Pearson mide relación lineal, de modo que una relación curva puede arrojar un valor cercano a cero.

8.15 Mapa de calor de una tabla cruzada

Qué muestra. La frecuencia o proporción de cada combinación de dos categóricas. **Cuándo usarlo.** Para examinar la relación entre dos variables categóricas. **Qué comunica.** Qué combinaciones resultan más frecuentes de lo esperado.

```
tabla = pd.crosstab(df["fila"], df["columna"], normalize="index").mul(100)

fig, eje = plt.subplots(figsize=(8, 4.5))
sns.heatmap(tabla, annot=True, fmt=".1f", cmap="Blues",
            cbar_kws={"label": "Porcentaje de la fila"}, ax=eje)
plt.tight_layout(); plt.show()
```



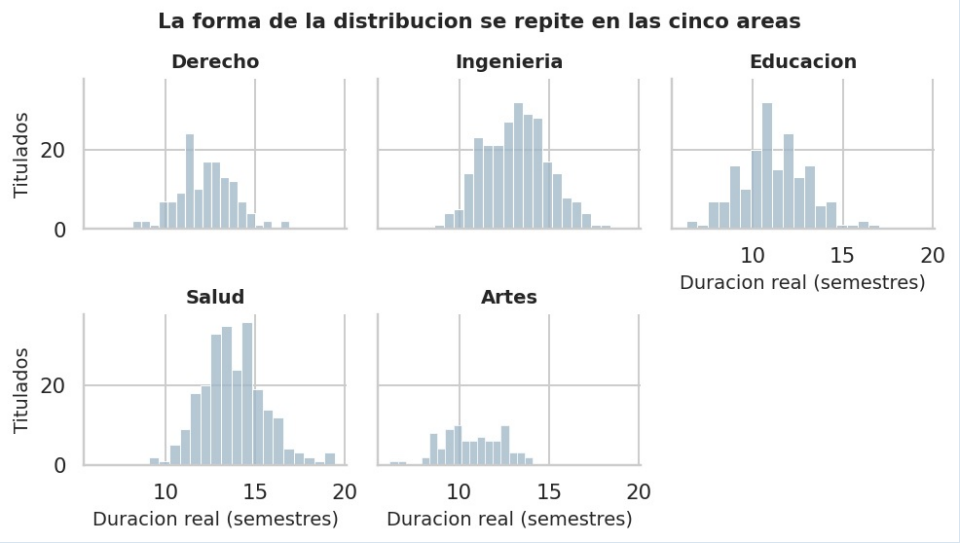
Ejemplo generado con el código anterior

Precaución. El argumento `normalize` determina qué se compara: por filas, por columnas o sobre el total. La interpretación cambia por completo según cuál se elija, de modo que debe declararse.

8.16 Paneles múltiples

Qué muestra. El mismo gráfico repetido para cada nivel de una variable. **Cuándo usarlo.** Cuando hay demasiadas series para una sola figura, o para estratificar. **Qué comunica.** Si un patrón se mantiene o se modifica entre subgrupos.

```
grilla = sns.FacetGrid(df, col="categoria", col_wrap=3, height=2.8, sharey=True)
grilla.map_dataframe(sns.histplot, x="variable", bins=20, color=NEUTRO)
grilla.set_axis_labels("Variable (unidad)", "Observaciones")
grilla.set_titles("{col_name}")
plt.tight_layout(); plt.show()
```



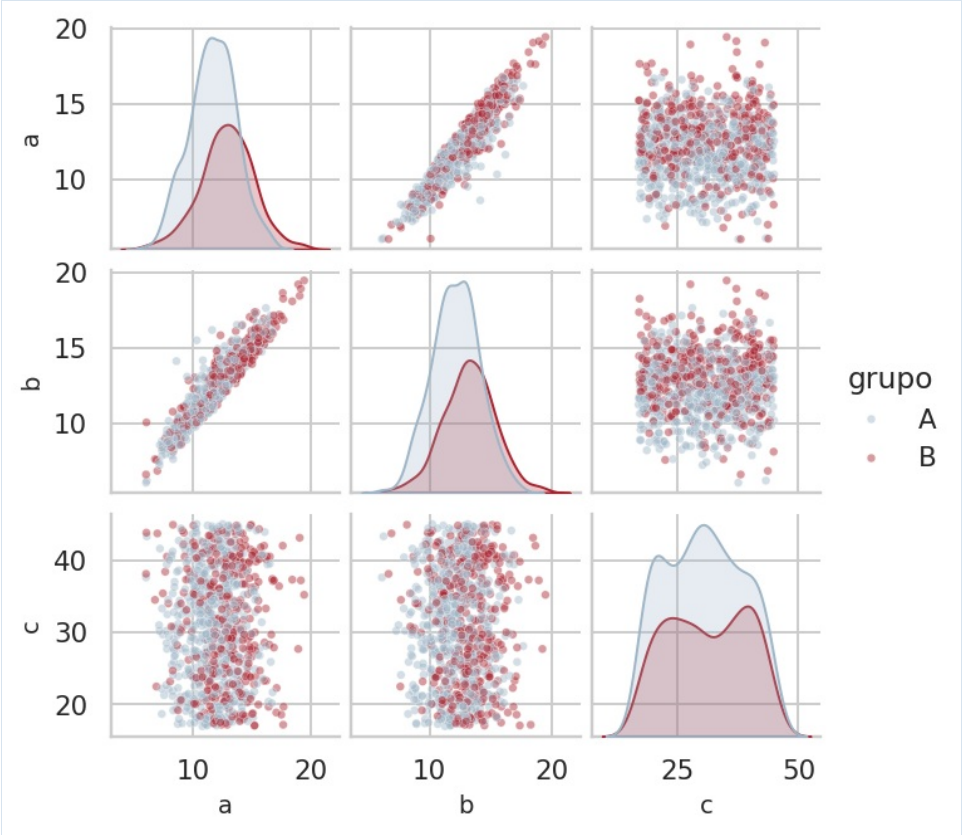
Ejemplo generado con el código anterior

> **Uso analítico.** Los paneles son la forma más simple de estratificar. Ante la sospecha de que una diferencia entre grupos se deba a una tercera variable, dividir por esa variable y observar si la diferencia persiste es el procedimiento que permite detectar confusión y la paradoja de Simpson. Los ejes deben mantenerse compartidos, o la comparación entre paneles pierde validez.

8.17 Matriz de dispersión

Qué muestra. Todas las combinaciones de pares entre varias variables. **Cuándo usarlo.** En la exploración, para detectar relaciones no anticipadas. **Qué comunica.** Un panorama de la estructura del conjunto.

```
sns.pairplot(df[["a", "b", "c", "grupo"]], hue="grupo",
             palette=[NEUTRO, DESTACADO], plot_kws={"s": 14, "alpha": 0.5})
plt.show()
```



Ejemplo generado con el código anterior

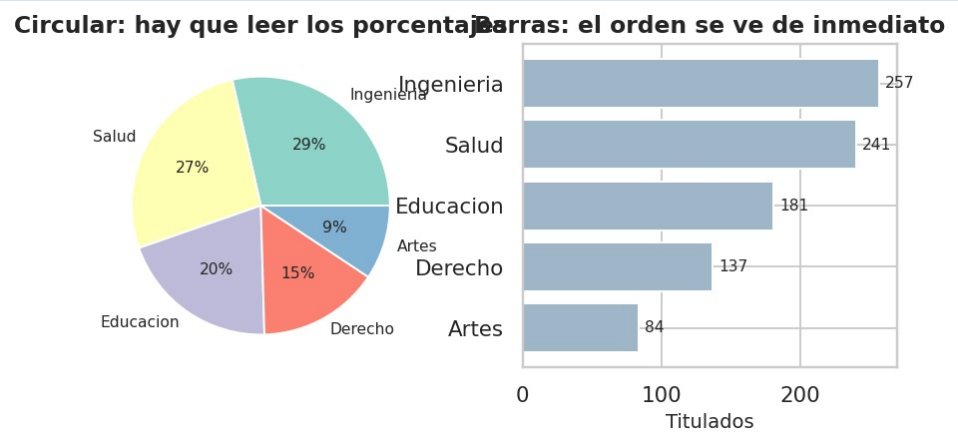
Precaución. Es una herramienta exploratoria: muestra mucho y no afirma nada. Su lugar son los anexos, no las figuras del informe.

8.18 Gráfico circular

Qué muestra. La composición de un total. **Cuándo usarlo.** Con dos o tres categorías, y aun así existen mejores opciones. **Qué comunica.** La proporción aproximada de cada parte.

```
frecuencias = df["categoria"].value_counts()

fig, eje = plt.subplots(figsize=(5.5, 5))
eje.pie(frecuencias.values, labels=frecuencias.index, autopct="%1.0f%%")
plt.tight_layout(); plt.show()
```



Ejemplo generado con el código anterior

Precaución. Codifica la magnitud mediante ángulo, que ocupa el cuarto lugar en la jerarquía de precisión perceptual. Con cinco porciones resulta necesario leer los porcentajes para ordenarlas, mientras que con barras horizontales el orden se percibe de inmediato.

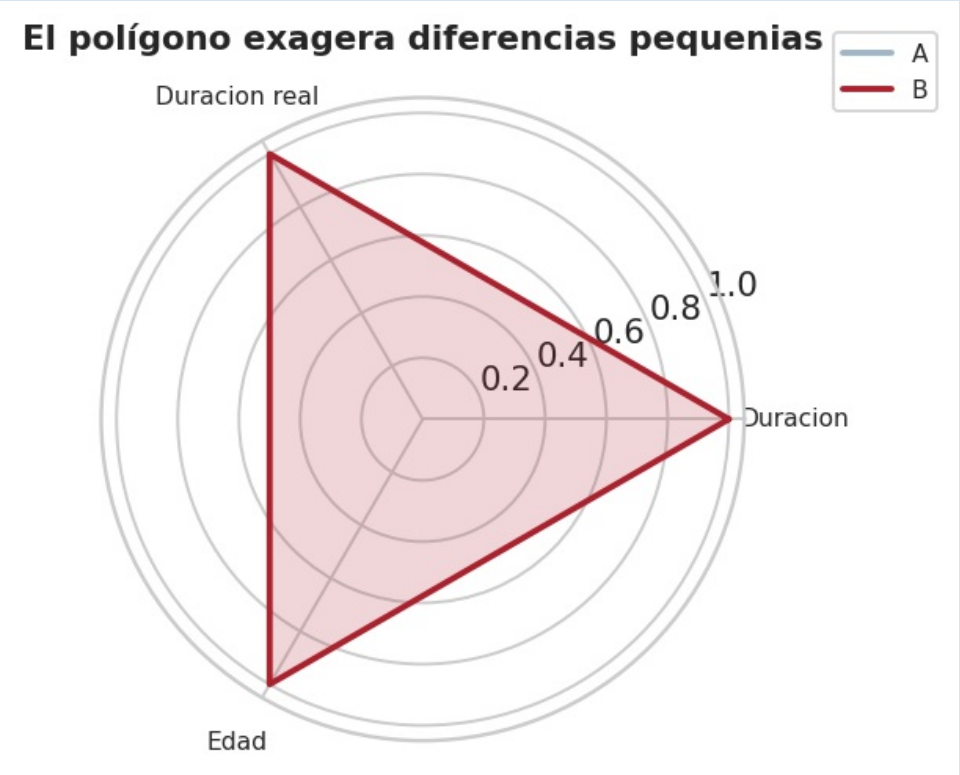
8.19 Radar

Qué muestra. El perfil de pocos grupos en varias dimensiones simultáneas. **Cuándo usarlo.** Para comparar dos o tres perfiles en cuatro o más variables. **Qué comunica.** En qué dimensiones los grupos se asemejan y en cuáles difieren.

```
variables = ["a", "b", "c"]
perfil = df.groupby("grupo", observed=True)[variables].mean()
perfil_n = (perfil - perfil.min()) / (perfil.max() - perfil.min())

angulos = np.linspace(0, 2 * np.pi, len(variables), endpoint=False).tolist()
angulos += angulos[:1]

fig, eje = plt.subplots(figsize=(5.5, 5.5), subplot_kw=dict(polar=True))
for (nombre, fila), color in zip(perfil_n.iterrows(), [NEUTRO, DESTACADO]):
    valores = fila.tolist() + fila.tolist()[:1]
    eje.plot(angulos, valores, linewidth=2, label=nombre, color=color)
    eje.fill(angulos, valores, alpha=0.18, color=color)
eje.set_xticks(angulos[:-1]); eje.set_xticklabels(variables)
eje.legend(loc="upper right")
plt.tight_layout(); plt.show()
```



Ejemplo generado con el código anterior

Precaución. Codifica mediante área, penúltimo lugar de la jerarquía perceptual. Al normalizar a la escala de cero a uno, el grupo con el valor más bajo queda siempre en el centro y el más alto en el borde, con independencia de la magnitud real de la diferencia. Debe acompañarse de los valores sin normalizar.

8.20 Tabla resumen

Qué muestra. Las cifras exactas. **Cuándo usarla.** Cuando el lector requiere valores precisos y no una impresión visual. **Qué comunica.** La magnitud exacta y el tamaño de cada grupo.

```
resumen = (df.groupby("grupo", observed=True)
           .agg(observaciones=("valor", "size"),
                mediana=("valor", "median"),
                media=("valor", "mean"),
                desviacion=("valor", "std"))
           .round(2))
print(resumen.to_string())
```

Cuando las cifras son pocas y todas importan, la tabla comunica mejor

Grupo	Observaciones	Mediana	Media	Desviacion
A	552	11.66	11.64	1.98
B	348	12.92	12.85	2.29

Ejemplo generado con el código anterior

Precaución. Una tabla no es un recurso menor frente a un gráfico. Cuando las cifras son pocas y todas relevantes, comunica mejor. Las figuras principales conviene acompañarlas de la tabla que las originó, aunque sea en anexos.

---

9. Síntesis para la elección

Si la pregunta es	El gráfico es	Alternativa
¿Cuánto tiene cada grupo?	Barras ordenadas	Tabla, si son pocos valores
¿Cómo se distribuyen los valores?	Histograma	Densidad, si se comparan grupos
¿Cómo se comparan las distribuciones?	Caja con puntos	Violín, si la forma importa
¿Se relacionan estas dos variables?	Dispersión	Con tendencia, si se requiere la pendiente
¿Cómo cambia en el tiempo?	Líneas	Áreas, con una sola serie
¿De qué se compone el total?	Barras apiladas al cien	Nunca circular con más de tres partes
¿Qué variables se parecen entre sí?	Mapa de calor	Matriz de dispersión, en anexos
¿El patrón persiste en los subgrupos?	Paneles múltiples	

> **Criterio ante la duda.** Si dos tipos parecen igualmente adecuados, conviene construir ambos y someterlos a una persona ajena al proyecto. El que se comprenda sin explicación adicional es el correcto.

10. De los hallazgos al relato

Un gráfico aislado informa; una secuencia de gráficos argumenta. La diferencia está en que cada figura cumpla un papel dentro de una progresión.

Movimiento	Función en el argumento
Contexto	Sitúa el fenómeno y establece su magnitud general
Contraste	Presenta la diferencia o el patrón que constituye el hallazgo
Resolución	Confirma el patrón sobre otra evidencia y declara sus límites

La continuidad entre figuras es lo que convierte tres gráficos en un argumento. Si la primera identifica un umbral, la tercera puede marcarlo explícitamente; si la segunda define dos grupos, las siguientes deben mantener los mismos colores para esos grupos.

La estructura de cada interpretación

Cada figura se acompaña de cuatro enunciados, en este orden.

1. **Qué muestra.** Descripción literal de lo representado, sin interpretar.
2. **Qué se infiere.** La lectura que el equipo hace de ese resultado.
3. **Qué límite tiene.** Hasta dónde alcanza la afirmación y bajo qué supuestos.
4. **Cómo aporta al relato.** Qué papel cumple la figura en la secuencia.

El tercero es el que distingue un informe técnico de una presentación persuasiva, y es el que con más frecuencia se omite. Declarar limitaciones no debilita el trabajo: lo hace verificable.

11. Interpretación y sus límites

La comunicación de resultados exige precisión sobre qué permite afirmar la evidencia disponible. Cuatro conceptos delimitan el alcance de casi cualquier hallazgo observacional.

> **Asociación y causalidad.** Que dos variables se presenten juntas no implica que una produzca la otra. Los datos observacionales, sin diseño experimental ni control de terceras variables, solo permiten afirmar asociación.

> **Variable de confusión.** Tercera variable asociada simultáneamente con las dos que se comparan, capaz de producir una asociación aparente entre ellas. Si dos grupos difieren en edad y la edad se relaciona con el desenlace, cualquier diferencia entre esos grupos puede deberse a la edad.

Sesgo de selección. Distorsión producida cuando quienes integran el conjunto analizado difieren sistemáticamente de la población sobre la que se quiere concluir. Un registro de procedimientos cerrados, por ejemplo, excluye los que siguen abiertos, que pueden ser precisamente los más complejos.

Paradoja de Simpson. Situación en que una relación observada en los datos agregados se invierte al analizar los subgrupos por separado. Es la manifestación más extrema del efecto de confusión y la razón por la que conviene estratificar antes de concluir.

Regla de redacción. Las conclusiones deben escribirse en el lenguaje que la evidencia permite. Corresponde decir que dos variables se asocian, que un grupo presenta una tasa mayor, o que se observa una diferencia. No corresponde decir que una variable causa, determina, explica o produce la otra.

12. El informe técnico como género

Un informe técnico no es una narración del trabajo realizado ni un manual del código. Responde a un lector que necesita decidir si los resultados son confiables y qué puede hacer con ellos.

Apartado	Pregunta que responde
Introducción	¿Por qué este problema importa y a quién?
Problemática y objetivos	¿Qué exactamente se propuso resolver, y qué queda fuera?
Metodología	¿Cómo se llegó al resultado y por qué se eligieron esos caminos?
Resultados	¿Qué se encontró, con qué evidencia?
Discusión	¿Qué significa, con qué limitaciones y qué riesgos?
Conclusiones	¿Qué se aprendió y qué debería hacerse después?

Dos exigencias que suelen subestimarse

La relevancia. La introducción debe declarar a quién sirve el resultado y qué decisión podría apoyarse en él. Una justificación que solo remite al propio trabajo, del tipo el análisis permitirá decidir qué mostrar en las tablas, no establece relevancia alguna.

La distinción entre alcance, restricciones y supuestos. El alcance declara qué se aborda y qué no. Las restricciones son límites impuestos por los datos, el tiempo o el acceso. Los supuestos son condiciones bajo las cuales los resultados son interpretables. Son tres categorías distintas y el descriptor las pide por separado.

13. La comunicación oral

La presentación audiovisual no es un resumen del informe leído en voz alta. Es un género propio, con restricciones distintas: el tiempo es limitado, el receptor no puede volver atrás y el apoyo visual compite con la voz.

Tramo	Contenido
Apertura	Equipo, nombre del proyecto y objetivo
Contexto	Problema y relevancia profesional
Metodología	Pipeline y herramientas, con evidencia visual
Resultados	Las figuras comentadas, no descritas
Conclusiones	Aprendizajes, límites y proyección

La diferencia entre comentar y describir una figura es sustantiva. Describir es decir que hay un gráfico de barras con la tasa por grupo. Comentar es decir qué se encontró y usar el gráfico como evidencia de ello.

14. Verificación final

Antes de entregar, conviene recorrer el trabajo con las siguientes preguntas.

Sobre las figuras. ¿Cada una responde un objetivo específico declarado? ¿El título afirma un hallazgo? ¿Los ejes declaran variable y unidad? ¿Hay fuente al pie? ¿Las escalas son fieles? ¿El color cumple una función?

Sobre la interpretación. ¿Cada figura tiene sus cuatro enunciados? ¿Alguna conclusión afirma causalidad? ¿Están declaradas las limitaciones y el tamaño de los grupos?

Sobre la consolidación. ¿El informe, los notebooks, el repositorio y la presentación afirman lo mismo? ¿Cada afirmación del informe puede verificarse en el repositorio? ¿El registro de cambios vincula cada mejora con su punto en el historial?

> **La verificación más rentable.** Abrir el repositorio desde una carpeta limpia, como lo haría un lector externo, y comprobar una por una las afirmaciones del informe. Es media hora de trabajo y detecta la mayor parte de los defectos que cuestan puntos.

15. Referencias

Cleveland, W. S., y McGill, R. (1984). Graphical perception: Theory, experimentation, and application to the development of graphical methods. *Journal of the American Statistical Association, 79*(387), 531 a 554.

Few, S. (2012). *Show me the numbers: Designing tables and graphs to enlighten* (2.ª ed.). Analytics Press.

Healy, K. (2018). *Data visualization: A practical introduction*. Princeton University Press.

Knaflic, C. N. (2015). *Storytelling with data: A data visualization guide for business professionals*. Wiley.

Munzner, T. (2014). *Visualization analysis and design*. CRC Press.

Tufte, E. R. (2001). *The visual display of quantitative information* (2.ª ed.). Graphics Press.

Wickham, H. (2010). A layered grammar of graphics. *Journal of Computational and Graphical Statistics, 19*(1), 3 a 28.